Projet Data Science 2025-2026

Le sujet

Les accidents corporels de la circulation routière représentent un enjeu majeur de santé publique et de sécurité en France. Chaque année, des milliers de personnes sont blessées ou perdent la vie sur les routes. Comprendre les facteurs qui influencent la gravité des accidents est essentiel pour mettre en place des politiques de prévention efficaces et réduire le nombre de victimes.

Vous êtes recrutés par une entreprise spécialisée en **analyse de données et en prévention des risques routiers**, qui collabore avec des collectivités et des institutions publiques afin d'améliorer la sécurité routière.

Votre mission est d'explorer les données des accidents corporels de la circulation routière en France (année 2024), de comprendre les facteurs influençant la gravité des accidents, et de développer un **modèle prédictif** capable d'estimer la gravité d'un accident à partir de ses caractéristiques.

Les données

Les données sont disponibles sur I-Campus sous le fichier :
accidents_2024.csv

Chaque ligne du fichier correspond à **un accident** (identifié par un numéro unique Num_Acc).

Les attributs de ces données sont les suivants :

- **Num_Acc** : identifiant unique de l'accident.
- **Département** : département où a eu lieu l'accident.
- **Agglomération** : indique si l'accident a eu lieu en agglomération ou hors agglomération.
- **Luminosité** : conditions de luminosité au moment de l'accident (jour, nuit, éclairage public...).
- **Météo (conditions atmos.)** : météo au moment de l'accident (normale, pluie, brouillard...).
- **Type de collision** : type de collision (frontale, arrière, latérale...).
- **Catégorie de route** : type de route (autoroute, route départementale, etc.).
- **Régime de circulation** : sens unique, bidirectionnel, chaussées séparées...
- **Nombre de voies** : nombre de voies sur la route.
- **État de la surface** : état de la chaussée (normale, mouillée, verglacée...).
- **Infrastructure** : infrastructure particulière (pont, tunnel, chantier...).
- **Situation de l'accident** : position de l'accident (sur chaussée, trottoir...).
- **Vitesse max autorisée** : limitation de vitesse sur la route.

- **Gravité (label)** : gravité de l'accident (variable cible à prédire) :
    - *Tué*
    - *Blessé hospitalisé*
    - *Blessé léger*

Objectifs du projet

1. Exploration et analyse des données

Vous commencerez par une phase exploratoire des données pour identifier les informations pertinentes. Vous utiliserez les techniques de visualisation des données vues au premier semestre pour mettre en lumière les facteurs pouvant influencer la gravité des accidents.

Vous devrez notamment :

- Analyser la répartition des accidents selon leur gravité (*Tué*, *Blessé hospitalisé*, etc.).
- Étudier l'impact de la météo, de la luminosité et du type de route sur la gravité.
- Visualiser les tendances significatives entre les variables explicatives et la gravité.
- Identifier les valeurs aberrantes et les incohérences éventuelles dans les données.
- Proposer des visualisations pertinentes (bar charts, heatmaps, pie charts, etc.) adaptées à un usage BI.

2. Nettoyage et préparation des données

- Traiter les valeurs manquantes ou incohérentes.
- Transformer les variables catégoriques (ex. : *Météo*, *Type de collision*, *Catégorie de route*) en variables numériques exploitables par les modèles.
- Normaliser ou standardiser les variables si nécessaire.
- Préparer un dataset propre et exploitable pour le Machine Learning.
-

3. Construction du modèle prédictif

Vous développerez un modèle de machine learning pour prédire la **gravité d'un accident** à partir des informations disponibles dans le dataset.

- Vous êtes libres de choisir les outils et algorithmes que vous jugez appropriés (ex. : KNN, Random Forest, Logistic Regression, Decision Tree).
- Vous évaluerez la performance de votre modèle à l'aide des métriques vues en cours (accuracy, précision, rappel, F1-score...).
- Vous devrez proposer un protocole de test solide (train/test split, validation croisée, etc.).

Attention : dans un contexte réel, une mauvaise prédiction de gravité pourrait avoir des conséquences importantes sur les décisions prises par les autorités (prévention, sécurité, investissements). Il est donc important d'analyser vos résultats avec rigueur.

Organisation

Vous vous répartirez en groupe de **2-3 étudiants**.

Vous disposez de **9 séances de 3h** de travail pour réaliser le projet en autonomie.

Il n'y a pas d'enseignant durant les séances en autonomie. Cependant, n'hésitez pas à solliciter vos enseignants si vous avez des questions sur les différents aspects du projet :

- **M. Almaksour** pour Data Science.
- **M. Demoli** pour Data Visualisation.

Rendu attendu

Vous devrez réaliser un **rapport de 10 pages maximum** qui décrira votre démarche, vos résultats, et vos conclusions.

Voici les points que vous devez aborder et faire attention dans votre rapport (liste non exhaustive) :

- Une introduction qui décrit les données récoltées et vos questions d'intérêts.
- La qualité des justifications de choix d'analyse afin de répondre aux questions.
- La qualité des visualisations (lisibilité, clarté, autosuffisance, etc.).
- Le choix de la visualisation vis-à-vis de l'analyse effectuée.
- L'originalité et la validité des conclusions tirées des visualisations.
- La bonne utilisation des techniques statistiques.
- Le choix de la méthode de résolution à utiliser pour la prédiction et sa calibration.
- L'évaluation de la qualité de vos résultats :
    - Votre protocole : Pourquoi votre méthode donne de bons résultats ou pas (sur quels jeux de données vous avez testé, en les découpant comment, en évaluant combien de fois, séparation apprentissage/test, etc.).
    - Votre protocole est complet s'il est suffisant pour que vos résultats soient reproductibles par une autre personne à partir du même jeu de données.
    - Les tableaux de résultats obtenus.
    - L'interprétation des résultats obtenus.

Vous devrez également présenter votre projet en **10 minutes** lors de la soutenance orale.

Vous devrez présenter votre démarche, vos résultats, et vos conclusions. Vous devrez également répondre aux questions de vos enseignants.

Bonus

Tester et évaluer plusieurs algorithmes de classification afin d'identifier le plus performant dans ce contexte.

Sujet alternatif

Vous êtes également libres de travailler sur un autre sujet de votre choix à condition que cela soit validé par vos deux professeurs.